DataWarehouse: DW01: Pentaho Data Integration (Kettle) para datos meteorológicos

Realizado por

Olga Cantalejo Gómez y Paula María Suárez Linares

Grado en Ingeniería Informática- Ingeniería del Software

Complementos de Base de Datos

Índice

Índice de figuras 3
1. Introducción 4
1.1 Contexto 4
1.2 Objetivo del Proyecto 4
1.3 Stack Tecnológico y Herramientas utilizadas 5
1.3.1 Oracle Database 21c Express Edition (XE) 5
1.3.2 Oracle SQL Developer 5
1.3.3 Pentaho Data Integration (Spoon) 5
1.4 Descripción del origen de los datos 5
2. Diseño del Almacén de Datos 6
2. 1 Modelo de datos 6
2.2 Descripción de Tablas 7
2.3 Esquema lógico 8
3. Proceso ETL: Extracción, Transformación y Carga 9
3.1 Origen de datos 9
3.2 Flujo en Pentaho 10
3.3 Retos técnicos Superados 14
4. Manual de Despliegue e Instalación 14
4.1 Requisitos del Sistema 15
4.2 Instalación y Configuración del Entorno 15
4.3 Scripts SQL de Creación 15
5. Manual de Usuario 16
6. Resultados y Validación 16
6.1 Capturas de éxito 16
6.2 Verificación mediante consultas SQL 17
7. Conclusiones 21
8. Uso de IA 21
9. Bibliografía 22

Índice de figuras

Figura 1: Vista del archivo fuente CSV, donde se aprecian los separadores y la estructura original antes del proceso de limpieza. 6
Figura 2: Comparación Modelo Estrella con Modelo Copo de Nieve 7
Figura 3: Estructura y tipos de datos de la tabla DIM_CIUDAD 8
Figura 4: Estructura y tipos de datos de la tabla DIM_TIEMPO 9
Figura 5: Estructura y tipos de datos de la tabla FACT_RADIACION 9
Figura 6: Entrada Fichero de Texto - Contenido 10
Figura 7: Entrada Fichero de Texto - Campos 10
Figura 8: Filtrar Filas 11
Figura 9: Añadir valor constante – FECHA_DATO 11
Figura 10: Configuración Calculadora 12
Figura 11: Cargar_Dim_Ciudad 12
Figura 12: Cargar_Dim_Tiempo 13
Figura 13: Tabla Salida - FACT_RADIACION 14
Figura 14: Flujo con todos los checks en verde 17
Figura 15: Logs del flujo 17
Figura 16: Consulta de carga total 19
Figura 17: Consulta de análisis multidimensional 21

1. Introducción

1.1 Contexto

La Agencia Estatal de Meteorología (AEMET) tiene por objeto el desarrollo, implantación, y prestación de los servicios meteorológicos de competencia del Estado. Como autoridad meteorológica nacional, su papel es crucial no solo en la predicción del tiempo, sino en el apoyo a políticas de salud pública mediante la monitorización de variables ambientales.

La radiación ultravioleta es una forma de energía electromagnética emitida por el sol. Para entender su impacto, debemos categorizarla según su capacidad de penetración en la atmósfera:

- **UVA (400 - 320 nm):** Representa la mayor parte de la radiación que alcanza la superficie terrestre. Aunque tiene menos energía que la UVB, penetra profundamente en la piel.
- **UVB (320 - 290 nm):** Es absorbida en un 90% por el ozono. Es biológicamente muy activa y la principal responsable de las quemaduras solares.
- **UVC (290 - 200 nm):** Es la más energética y peligrosa, pero afortunadamente es absorbida totalmente por la capa de ozono, no llegando a la superficie.

Entre los factores medioambientales que influyen en el nivel de radiación ultravioleta se encuentran:

- Altura del sol (a mayor altura, mayor nivel de radiación)
- Latitud (a mayor proximidad al ecuador, mayor nivel de radiación)
- Presencia de nubles (a menor presencia, mayor radiación)
- Altitud (con cada incremento de 1.000 metros de altitud, incremento entre 10-12% en los niveles de radiación)
- Presencia de ozono (a menor presencia de ozono estratosférico mayor radiación ultravioleta)
- Reflejo en la superficie terrestre (la nieve puede reflejar hasta un 80% de la radiación y la arena de las playas en torno a un 15%).

Aunque pequeñas dosis son vitales para la síntesis de vitamina D, el Ministerio de Sanidad advierte que la sobreexposición es un problema de salud pública de primer orden. Los riesgos se dividen en:

1. **Patologías Cutáneas:** Desde eritemas (quemaduras) hasta daños en el ADN celular que pueden derivar en carcinomas y melanomas malignos.
2. **Daños Oculares:** La exposición prolongada sin protección aumenta la incidencia de cataratas y fotoqueratitis.
3. **Sistema Inmunitario:** Se ha demostrado que niveles altos de UV pueden debilitar la respuesta inmune del organismo.

1.2 Objetivo del Proyecto

Dada la peligrosidad de esta radiación y la multiplicidad de factores que influyen en ella, el análisis de datos brutos se vuelve insuficiente. Este proyecto justifica la creación de un Data Warehouse para centralizar la información de la AEMET, permitiendo que,

mediante herramientas de analítica, se puedan generar alertas y visualizaciones claras para proteger a la población vulnerable (niños, deportistas y trabajadores al aire libre).

1.3 Stack Tecnológico y Herramientas utilizadas

Para el desarrollo de la solución de BI, se ha seleccionado un conjunto de herramientas líderes en el sector que garantizan la escalabilidad y robustez del sistema:

1.3.1 Oracle Database 21c Express Edition (XE)

Actúa como el Sistema de Gestión de Bases de Datos Relacionales (RDBMS) central. Es el motor donde reside nuestro Data Warehouse. Se ha elegido la versión XE por ser una solución gratuita y potente para entornos de desarrollo, permitiendo gestionar el almacenamiento de las dimensiones y tablas de hechos mediante un motor de alto rendimiento capaz de manejar volúmenes de datos meteorológicos complejos.

1.3.2 Oracle SQL Developer

Es el Entorno de Desarrollo Integrado (IDE) utilizado para la administración de la base de datos. Funciona como la interfaz gráfica que permite la comunicación directa con el motor Oracle mediante comandos SQL. Su función principal en este proyecto ha sido la creación de la estructura del esquema (tablas, claves primarias y relaciones) y la posterior validación y consulta de los datos cargados.

1.3.3 Pentaho Data Integration (Spoon)

Es la herramienta de ETL (Extracción, Transformación y Carga) fundamental del proyecto. A través de su interfaz gráfica (Spoon), se han diseñado los flujos de datos necesarios para extraer la información desde los archivos fuente en formato CSV (AEMET), aplicar las transformaciones de limpieza y tipado de datos necesarias, y finalmente automatizar la carga en el modelo en estrella de nuestra base de datos Oracle.

1.4 Descripción del origen de los datos

La fuente de información primaria para este proyecto es el portal oficial de la Agencia Estatal de Meteorología (AEMET), específicamente su red de monitorización de radiación solar. Los datos se han obtenido en formato CSV (Comma Separated Values) a través de su servicio de predicción y datos observados.

El archivo descargado contiene los registros de los niveles de radiación ultravioleta máxima previstos y observados en diferentes estaciones de medición distribuidas por el territorio nacional. Estos datos son captados por radiómetros de banda ancha que miden la irradiancia eritremática integrada, proporcionando el valor del Índice UV (UVI).

El origen de datos presenta una estructura de tabla plana que incluye, entre otros, los siguientes campos críticos para nuestro análisis:

- **Identificador de Estación:** Código único de la ubicación de medida.
- **Fecha/Hora:** Momento cronológico de la observación.
- **Índice UV (Valor):** La variable cuantitativa principal que representa la intensidad de la radiación.

Para la justificación del uso de una herramienta de ETL (Pentaho), es importante señalar que los datos en bruto presentaban retos que impedían su uso directo en una base de datos relacional sin tratamiento previo:

1. **Formatos de Cabecera:** Presencia de caracteres especiales y espacios que dificultan la creación de tablas en SQL.
2. **Valores Nulos/Ausentes:** Existencia de celdas vacías en periodos donde la estación pudo estar inactiva o en mantenimiento, lo que requiere una lógica de limpieza para no desvirtuar las medias estadísticas.
3. **Tipado de Datos:** La necesidad de convertir cadenas de texto (strings) en formatos de fecha y números decimales compatibles con el motor Oracle 21c XE.

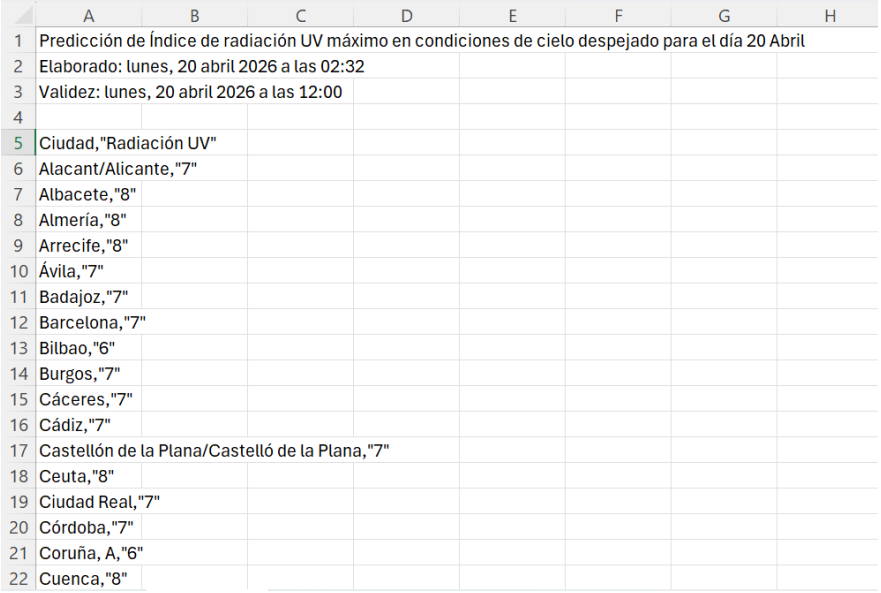

	A	B	C	D	E	F	G	H
1	Predicción de Índice de radiación UV máximo en condiciones de cielo despejado para el día 20 Abril							
2	Elaborado: lunes, 20 abril 2026 a las 02:32							
3	Validez: lunes, 20 abril 2026 a las 12:00							
4								
5	Ciudad,"Radiación UV"							
6	Alacant/Alicante,"7"							
7	Albacete,"8"							
8	Almería,"8"							
9	Arrecife,"8"							
10	Ávila,"7"							
11	Badajoz,"7"							
12	Barcelona,"7"							
13	Bilbao,"6"							
14	Burgos,"7"							
15	Cáceres,"7"							
16	Cádiz,"7"							
17	Castellón de la Plana/Castelló de la Plana,"7"							
18	Ceuta,"8"							
19	Ciudad Real,"7"							
20	Córdoba,"7"							
21	Coruña, A,"6"							
22	Cuenca,"8"							

Figura 1: Vista del archivo fuente CSV, donde se aprecian los separadores y la estructura original antes del proceso de limpieza.

2. Diseño del Almacén de Datos

En este capítulo se describe la arquitectura lógica y física del repositorio de datos diseñado para el análisis de la radiación ultravioleta.

2. 1 Modelo de datos

Para este proyecto se ha optado por un Modelo en Estrella, que es el estándar de facto en el diseño de almacenes de datos (Data Warehousing) para Business Intelligence.

Este modelo se caracteriza por tener una tabla central de Hechos (Fact Table) rodeada de tablas de Dimensiones (Dimension Tables). Las razones por las que hemos elegido esta estructura son:

- **Simplicidad en las consultas**: Facilita la realización de Joins sencillos entre la tabla de hechos y las dimensiones.
- **Rendimiento**: Está optimizado para consultas de agregación (sumas, medias, máximos) que son comunes en el análisis meteorológico.

- **Claridad semántica**: Separa claramente las métricas cuantitativas (el índice de radiación) de los descriptores cualitativos (la ciudad y el momento del tiempo).

El grano definido para la tabla FACT_RADIACION es de nivel diario por sede. Esto significa que cada registro representa la medición máxima de radiación UV para una ciudad específica en un día concreto. Este nivel de granularidad permite análisis temporales precisos y comparativas geográficas sin pérdida de detalle.

A pesar de que existen alternativas como el modelo en Copo de Nieve (Snowflake), se ha optado por el Modelo en Estrella por las siguientes ventajas competitivas para este proyecto:

- **Eficiencia en el procesamiento (Performance):** Al estar "desnormalizado", el modelo en estrella requiere menos uniones (*joins*) entre tablas. En un entorno de Business Intelligence, esto se traduce en una mayor velocidad de respuesta al generar informes de radiación UV.
- **Facilidad de mantenimiento del ETL:** Al reducir la jerarquía de las dimensiones, el flujo de datos en Pentaho es más directo y menos propenso a errores de integridad referencial durante la carga masiva.
- **Usabilidad:** Este modelo es el estándar que mejor entienden las herramientas de visualización de datos, facilitando que cualquier analista pueda explorar los datos de la AEMET sin necesidad de conocer una estructura de base de datos compleja.

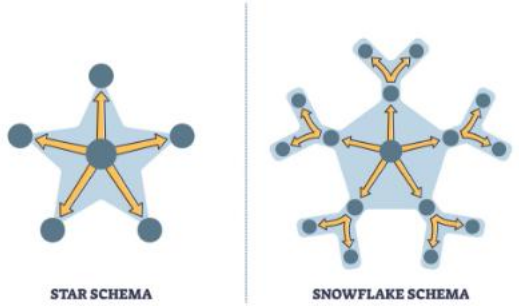

Figura 2: Comparación Modelo Estrella con Modelo Copo de Nieve

2.2 Descripción de Tablas

A continuación, se detallan las tres tablas que componen nuestro modelo en el esquema METEO_ESTRELLA:

A. Tabla de Dimensión: DIM_CIUDAD

Esta dimensión permite filtrar y agrupar los datos por ubicación geográfica. En el contexto de la AEMET, representa las sedes o estaciones de medición.

- **ID_CIUDAD (PK):** Clave primaria numérica. Se ha configurado como GENERATED BY DEFAULT AS IDENTITY para permitir la gestión de claves subrogadas desde el proceso ETL.
- **NOMBRE_CIUDAD:** Almacena el nombre oficial de la sede (ej. Albacete, Madrid, Santa Cruz de Tenerife).

B. Tabla de Dimensión: DIM_TIEMPO

Representa la granularidad temporal de nuestro análisis. Aunque actualmente trabajamos con datos diarios, esta estructura permite futuras expansiones (mes, año, festivos).

- **ID_TIEMPO (PK):** Clave primaria que identifica de forma única cada fecha.
- **FECHA:** Atributo de tipo fecha que registra el día de la medición.

C. Tabla de Hechos: FACT_RADIACION

Es el núcleo del modelo donde se cruzan las dimensiones y se almacena el dato medible.

- **ID_CIUDAD (FK):** Clave foránea que referencia a DIM_CIUDAD. Se ha optado por el uso de claves subrogadas (Surrogate Keys) mediante identificadores numéricos en lugar de claves naturales (nombres de ciudades). Esta decisión de diseño mejora el rendimiento de los índices en Oracle, reduce el espacio de almacenamiento en la tabla de hechos y aísla el modelo de posibles cambios en los nombres de las sedes o errores de tipografía en el origen de datos (CSV).
- **ID_TIEMPO (FK):** Clave foránea que referencia a DIM_TIEMPO.
- **INDICE_UV:** Métrica principal de tipo entero (Integer) que representa el índice de radiación ultravioleta máximo previsto.

El uso del comando GENERATED BY DEFAULT AS IDENTITY en Oracle 21c garantiza que el motor asigne automáticamente un ID numérico único. Esto es una buena práctica de Business Intelligence, ya que permite que el sistema sea independiente de los códigos que use la AEMET en sus archivos CSV, evitando errores si la fuente cambia su nomenclatura en el futuro.

2.3 Esquema lógico

El esquema se basa en una relación de **1 a N** (uno a muchos) desde las dimensiones hacia la tabla de hechos. Esto significa que una ciudad (o una fecha) puede tener múltiples registros de radiación asociados en la tabla de hechos, pero cada registro de la tabla de hechos pertenece a una única ciudad y a una única fecha específica.

Para garantizar la consistencia del almacén, se han implementado restricciones de integridad referencial (Foreign Keys). Esto asegura que no se pueda cargar un hecho de radiación en la tabla central si el identificador de la ciudad o del tiempo no existe previamente en sus respectivas dimensiones, evitando así la aparición de 'datos huérfanos'.

DIM_CIUDAD

Columnas | Datos | Model | Restricciones | Permisos | Estadísticas | Disparadores | Flashback | Dependencias | Detalles | Particiones | Índices | SQL

Acciones...

	COLUMN_NAME	DATA_TYPE	NULLABLE	DATA_DEFAULT	COLUMN_ID	COMMENTS
1	ID_CIUDAD	NUMBER	No	"METEO_ESTRELLA"."ISEQ$$_76154".nextval	1	(null)
2	NOMBRE_CIUDAD	VARCHAR2(100 BYTE)	Yes	(null)	2	(null)

Figura 3: Estructura y tipos de datos de la tabla DIM_CIUDAD

DIM_TIEMPO

Columnas | Datos | Model | Restricciones | Permisos | Estadísticas | Disparadores | Flashback | Dependencias | Detalles | Particiones | Índices | SQL

Acciones...

	COLUMN_NAME	DATA_TYPE	NULLABLE	DATA_DEFAULT	COLUMN_ID	COMMENTS
1	ID_TIEMPO	NUMBER	No	"METEO_ESTRELLA"."ISEQ$$_76164".nextval	1	(null)
2	FECHA	DATE	Yes	(null)	2	(null)
3	DIA	NUMBER	Yes	(null)	3	(null)
4	MES	NUMBER	Yes	(null)	4	(null)
5	ANIO	NUMBER	Yes	(null)	5	(null)

Figura 4: Estructura y tipos de datos de la tabla DIM_TIEMPO

FACT_RADIACION

Columnas | Datos | Model | Restricciones | Permisos | Estadísticas | Disparadores | Flashback | Dependencias | Detalles | Particiones | Índices | SQL

Acciones...

	COLUMN_NAME	DATA_TYPE	NULLABLE	DATA_DEFAULT	COLUMN_ID	COMMENTS
1	ID_CIUDAD	NUMBER(38,0)	Yes	(null)	1	(null)
2	ID_TIEMPO	NUMBER(38,0)	Yes	(null)	2	(null)
3	INDICE_UV	NUMBER(38,0)	Yes	(null)	3	(null)

Figura 5: Estructura y tipos de datos de la tabla FACT_RADIACION

3. Proceso ETL: Extracción, Transformación y Carga

El proceso ETL (Extract, Transform, Load) es el pilar que permite mover los datos desde el origen bruto hasta el almacén de datos estructurado. Para este proyecto, se ha diseñado un flujo robusto en Pentaho Data Integration capaz de manejar inconsistencias en el origen.

3.1 Origen de datos

El archivo de origen es un CSV suministrado por la AEMET con los datos de radiación ultravioleta. Tras un análisis preliminar del fichero radiacionuv.csv, se detectaron varios retos de limpieza (Data Cleaning):

- **Estructura No Estándar:** El archivo no comienza directamente con los datos. Contiene 4 líneas de cabecera descriptivas que deben ser ignoradas para que el motor ETL no las interprete como registros.
- **Inconsistencia en el Pie de Página:** Al final de las 59 sedes meteorológicas, el archivo incluye una línea de cierre (línea 60) con valores nulos o metadatos (null;null). Esta fila genera errores críticos de conversión de tipos al intentar procesarse como un dato numérico.

- **Formato de Valores:** Los datos de radiación se presentan inicialmente como cadenas de texto, requiriendo una tipificación explícita a entero para su posterior análisis.

3.2 Flujo en Pentaho

Se ha desarrollado una transformación en Kettle (.ktr) que sigue un flujo lineal de procesamiento:

A. Entrada Fichero de Texto (Extracción)

Es el punto de inicio donde se lee el archivo local.

- **Configuración:** Se definió el separador por punto y coma (;).
- **Gestión de Cabeceras:** En la pestaña *Contenido*, se configuró el salto de las primeras 4 líneas.
- **Optimización:** En la pestaña *Campos*, se aplicó un "Tipo de poda" (*Trim type*) de tipo ambos a las columnas para eliminar espacios en blanco accidentales que pudieran falsear los datos.

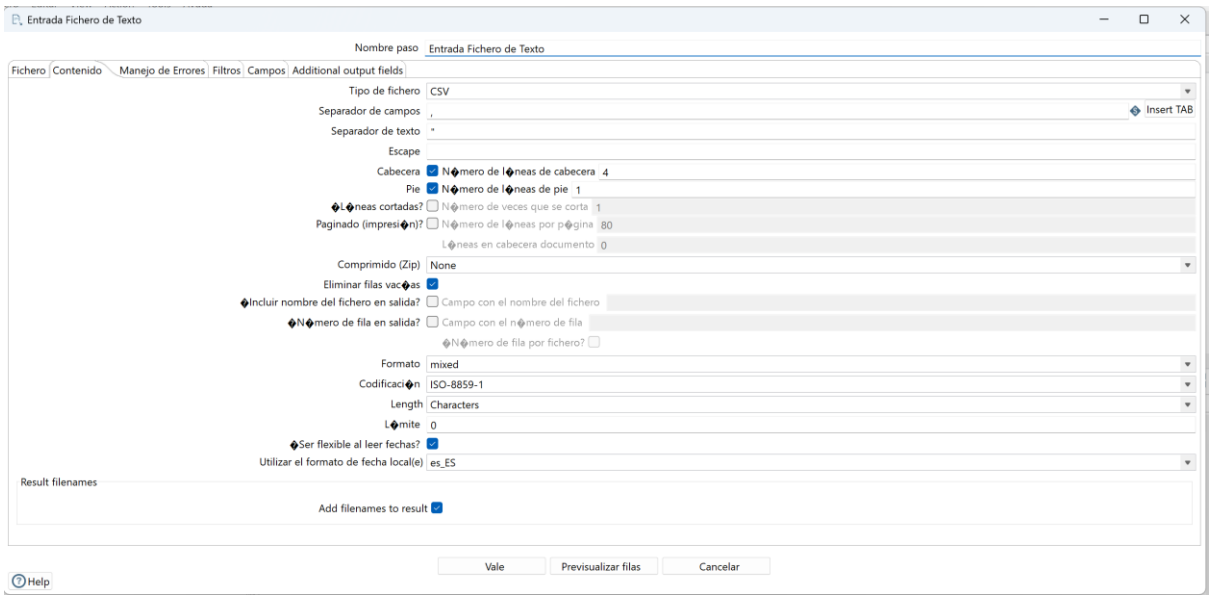

Figura 6: Entrada Fichero de Texto - Contenido

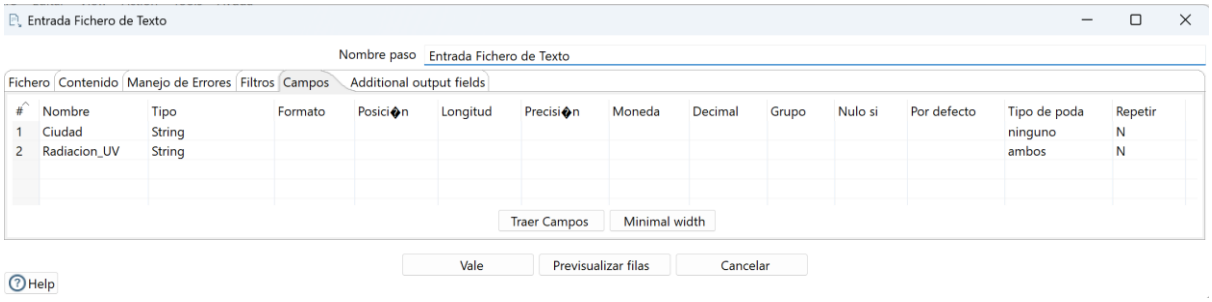

Figura 7: Entrada Fichero de Texto - Campos

B. Filtrado y Limpieza (Footer)

Para evitar el error de la línea 60 detectado en el análisis, se implementó una estrategia de exclusión:

- **Configuración de Pie de Fichero:** Se indicó en el paso de entrada que el archivo cuenta con 1 línea de pie de página. Esto indica a Pentaho que ignore la última fila del CSV, asegurando que solo pasen al flujo las 59 ciudades con datos válidos.

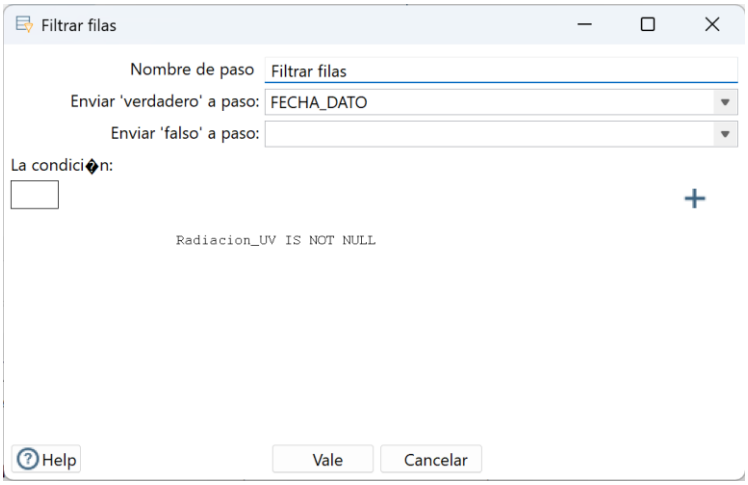

Figura 8: Filtrar Filas

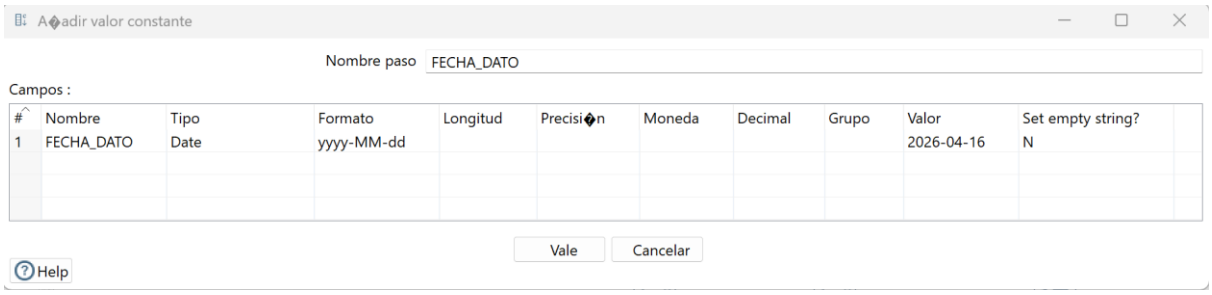

Figura 9: Añadir valor constante – FECHA_DATO

C. Calculadora (Transformación de Tipos)

Oracle requiere que el campo INDICE_UV sea numérico, pero el CSV lo entrega como texto.

- **Operación:** Se utilizó la función Create a copy of field A.
- **Conversión:** Se creó el campo **INDICE_V2** configurando explícitamente el tipo de dato como **Integer**. Esta "traducción" es vital para la integridad del almacén de datos.

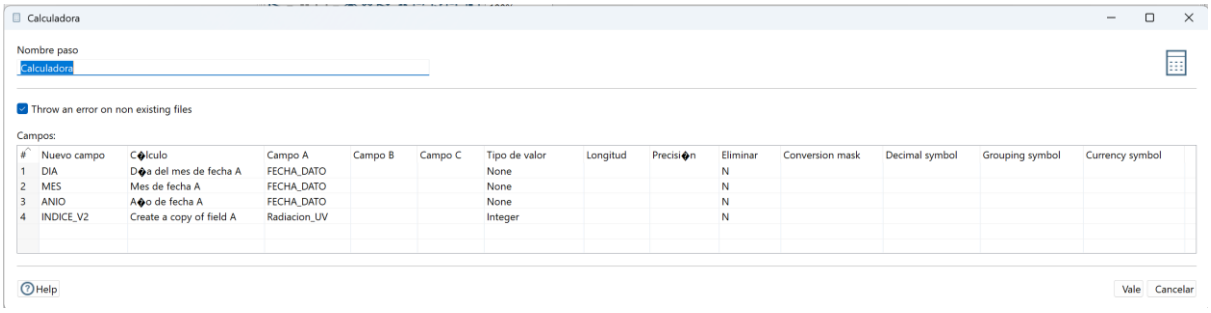

Figura 10: Configuración Calculadora

D. Carga en Dimensiones y Hechos

Finalmente, los datos se distribuyen en el esquema METEO_ESTRELLA:

- **Dimensiones:** Se cargan DIM_CIUDAD y DIM_TIEMPO, gestionando las fechas para que coincidan con el formato de Oracle.
- **Hechos:** El paso Table Output (FACT_RADIACION) realiza el mapeo final, enviando INDICE_V2 a la columna INDICE_UV de la base de datos.

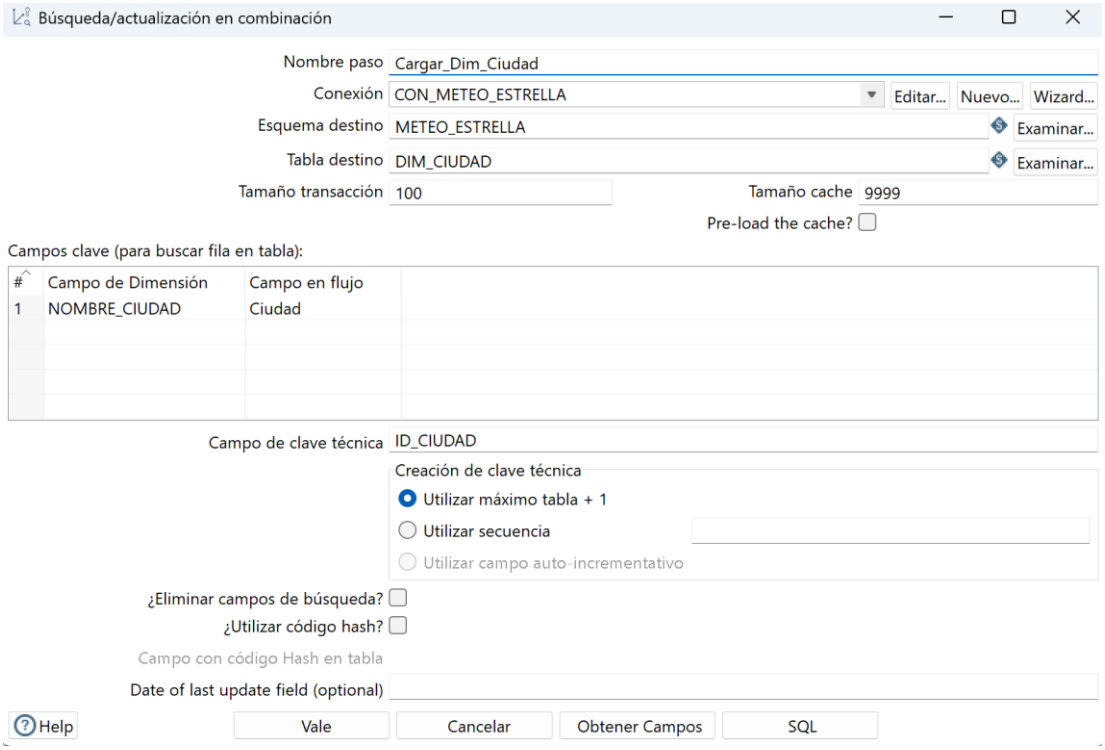

Figura 11: Cargar_Dim_Ciudad

Búsqueda/actualización en combinación

Nombre paso: Cargar_Dim_Tiempo
Conexión: CON_METEO_ESTRELLA — Editar... Nuevo... Wizard...
Esquema destino: Examinar...
Tabla destino: DIM_TIEMPO — Examinar...
Tamaño transacción: 100 — Tamaño cache: 9999
Pre-load the cache? ☐

Campos clave (para buscar fila en tabla):

#	Campo de Dimensión	Campo en flujo
1	DIA	DIA
2	FECHA	FECHA_DATO
3	MES	MES
4	ANIO	ANIO

Campo de clave técnica: ID_TIEMPO

Creación de clave técnica
- (●) Utilizar máximo tabla + 1
- ( ) Utilizar secuencia
- ( ) Utilizar campo auto-incrementativo

¿Eliminar campos de búsqueda? ☐
¿Utilizar código hash? ☐
Campo con código Hash en tabla
Date of last update field (optional)

Help | Vale | Cancelar | Obtener Campos | SQL

Figura 12: Cargar_Dim_Tiempo

Salida de Tabla

Nombre paso: FACT_RADIACION
Conexión: CON_METEO_ESTRELLA — Editar... Nuevo... Wizard...
Esquema destino: METEO_ESTRELLA — Examinar...
Tabla destino: FACT_RADIACION — Examinar...
Tama►o transacci►n (commit): 1000
Vaciar tabla ☐
Ignorar errores de inserci►n ☐
Specify database fields ☑

Main options | Database fields

Repartir informaci►n en varias tablas ☐
Campo de partici►n
Particionar informaci►n por mes
Particionar informaci►n por d►as

Utilizar actualizaci►n por lotes para inserciones ☑

►El nombre de la tabla est► definido en un campo? ☐
Campo que contiene el nombre de la tabla:
Almacena el campo con el nombre de tabla ☑

Incluye clave auto-generada ☐
Nombre del campo clave auto-generada

Help | Vale | Cancelar | SQL

Figura 13: Tabla Salida - FACT_RADIACION

3.3 Retos técnicos Superados

Durante el desarrollo, se enfrentaron desafíos técnicos que requirieron ajustes profundos en la configuración:

- **Resolución del error de conexión ORA-12505 (SID vs Service Name)**: Inicialmente, la conexión entre Pentaho y Oracle XE fallaba debido a la configuración por defecto de los drivers JDBC.
    - **Problema:** Pentaho intentaba conectar usando el SID convencional (xe), pero la base de datos Oracle 21c funciona mediante nombres de servicio (Service Name).
    - **Solución:** Se editó la conexión de base de datos en Pentaho para utilizar el nombre de servicio específico del contenedor de la base de datos (/XEPDB1), permitiendo un enlace exitoso.

- **Limpieza de datos:** gestión de metadatos y registros no estructurados en el origen CSV.
    - **Problema:** Intentamos procesar el origen de datos utilizando el componente estándar CSV file input, pero este no permitía omitir selectivamente las 4 líneas de metadatos de la cabecera ni la línea de resumen del pie de página (footer) de la AEMET. Esto provocaba errores de formato y tipos de datos al intentar iniciar la lectura
    - **Solución:** Sustituimos el componente por Text file input, que ofrece una configuración granular. Se configuró el salto de cabecera (Header) y se activó la opción de omitir el pie de página (Footer). Complementamos esto con un paso de Filter Rows para asegurar que solo los registros con datos meteorológicos válidos entraran al flujo.

- **Ajuste de claves de identidad en Oracle (GENERATED BY DEFAULT)**: La carga de la dimensión de ciudades presentó conflictos de permisos de escritura en las claves primarias.
    - **Problema:** La tabla se creó originalmente con GENERATED ALWAYS AS IDENTITY, lo que impedía que Pentaho insertara o gestionara sus propios IDs durante el proceso de carga masiva.
    - **Solución:** Se ejecutó un comando ALTER TABLE para modificar la restricción a GENERATED BY DEFAULT AS IDENTITY. Esto otorga flexibilidad al proceso ETL para manejar las claves subrogadas mientras se mantiene la capacidad de autogeneración de la base de datos.

4. Manual de Despliegue e Instalación

Este capítulo detalla los requisitos técnicos y los pasos necesarios para replicar el entorno de ejecución del proyecto.

4.1 Requisitos del Sistema

Para la correcta ejecución de la solución ETL, el sistema debe contar con el siguiente software instalado:

- **Java Runtime Environment (JRE) o JDK:** Versión 8 o 11 (requerida por Pentaho para su funcionamiento).
- **Pentaho Data Integration (PDI / Kettle):** Versión 9.x o superior (utilizada la versión 11 para este proyecto).
- **Oracle Database 21c Express Edition (XE):** Instancia local de base de datos donde reside el esquema METEO_ESTRELLA.
- **Oracle SQL Developer:** Herramientas de gestión para la ejecución de scripts y verificación de datos.

4.2 Instalación y Configuración del Entorno

i. **Driver JDBC:** Para que Pentaho pueda comunicarse con Oracle, se debe descargar el archivo ojdbc8.jar (o versión compatible) y copiarlo en la carpeta data-integration/lib del directorio de instalación de Pentaho.
ii. **Configuración de Red Oracle:** Asegurarse de que el listener de Oracle está activo y que el servicio XEPDB1 es accesible.
iii. **Conexión en Pentaho:** Dentro de Spoon, crear una nueva conexión de base de datos de tipo "Oracle" utilizando los parámetros de *Service Name* en lugar de SID para evitar errores de red.

4.3 Scripts SQL de Creación

Antes de ejecutar el proceso ETL, se deben preparar las estructuras en Oracle mediante los siguientes comandos:

-- Creación de la Dimensión Ciudad

```
CREATE TABLE DIM_CIUDAD (
   ID_CIUDAD NUMBER GENERATED BY DEFAULT AS IDENTITY PRIMARY
    KEY,
   NOMBRE_CIUDAD VARCHAR2(100)
);
```

-- Creación de la Dimensión Tiempo

```
CREATE TABLE DIM_TIEMPO (
   ID_TIEMPO NUMBER PRIMARY KEY,
   FECHA DATE,
   DIA NUMBER,
   MES NUMBER,
   ANIO NUMBER
```

```
);

-- Creación de la Tabla de Hechos
CREATE TABLE FACT_RADIACION (
   ID_CIUDAD NUMBER,
   ID_TIEMPO NUMBER,
   INDICE_UV NUMBER,
   CONSTRAINT FK_CIUDAD FOREIGN KEY (ID_CIUDAD) REFERENCES DIM_CIUDAD(ID_CIUDAD),
   CONSTRAINT FK_TIEMPO FOREIGN KEY (ID_TIEMPO) REFERENCES DIM_TIEMPO(ID_TIEMPO)
);
```

5. Manual de Usuario

Este manual describe el procedimiento para ejecutar la carga de datos de forma periódica o puntual.

1. **Apertura del proyecto:** Iniciar Pentaho Spoon y abrir el archivo de transformación Transformacion_Radiacion.ktr.
2. **Configuración del origen**: Hacer doble clic en el paso Entrada Fichero de Texto. En la pestaña "Fichero", pulsar en "Navegar" para seleccionar la ubicación local del archivo radiacionuv.csv descargado de la AEMET.
3. **Ejecución:** Pulsar el botón de "Play" (triángulo azul) en la barra de herramientas superior.
4. **Monitorización:** * Verificar que todos los iconos del flujo muestran un **check verde**, lo que indica éxito en el procesamiento.
    a. Revisar la pestaña **Logging** en la parte inferior para confirmar que se han leído 60 líneas (incluyendo cabeceras) y se han escrito exactamente **59 registros** en la base de datos.
5. **Verificación final:** Abrir SQL Developer y ejecutar la consulta SELECT * FROM FACT_RADIACION para confirmar la persistencia de los datos.

6. Resultados y Validación

En este capítulo se presenta la validación final del sistema, demostrando que el flujo ETL procesa los datos correctamente y que estos son persistidos de forma íntegra en el almacén de datos de Oracle.

6.1 Capturas de éxito

La validación visual del proceso en Pentaho Spoon confirma que no se produjeron errores durante la ejecución. Todos los pasos del flujo muestran el icono de verificación verde,

lo que indica que la lógica de extracción, limpieza y transformación se ha completado según lo previsto.

- **Ejecución Final:** Se procesaron con éxito las 59 ciudades proporcionadas por la AEMET.
- **Métricas de Salida:** El log de ejecución confirma que se ignoraron las líneas de cabecera y el pie de página, resultando en una carga limpia de 59 registros en la tabla de hechos.

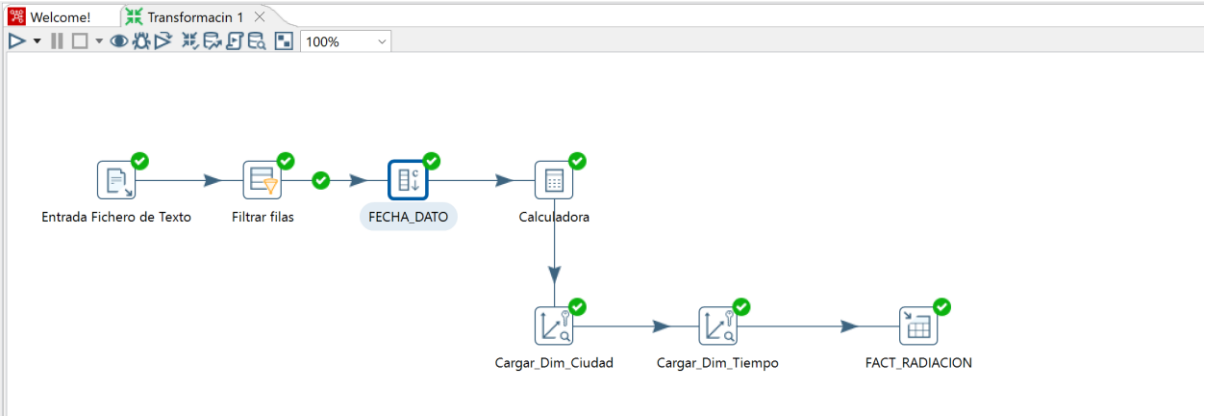

Figura 14: Flujo con todos los checks en verde

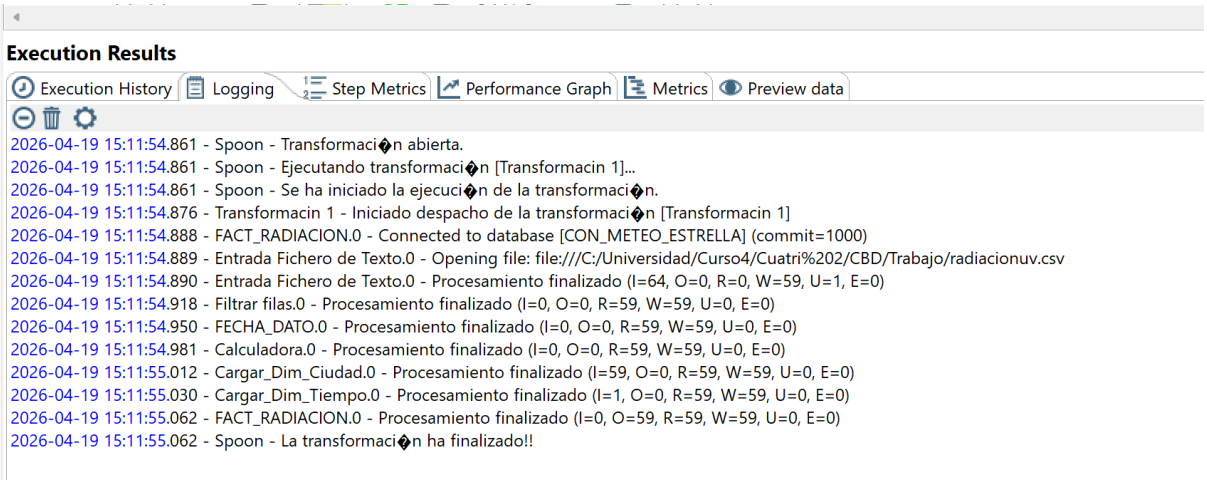

Figura 15: Logs del flujo

6.2 Verificación mediante consultas SQL

Para validar la integridad referencial y la calidad de la carga, se realizaron consultas directamente sobre el esquema METEO_ESTRELLA en Oracle.

A. Consulta de carga total

Se verificó que el número de filas en la tabla de hechos coincide con el número esperado de estaciones meteorológicas procesadas.

COMANDO:

```
SELECT * FROM METEO_ESTRELLA.FACT_RADIACION;
```

RESULTADO:

Resultado de la Consulta

SQL | Todas las Filas Recuperadas: 59 en 0,051 segundos

	ID_CIUDAD	ID_TIEMPO	INDICE_UV
1	2	1	7
2	32	1	7
3	3	1	8
4	33	1	9
5	4	1	7
6	34	1	7
7	5	1	6
8	35	1	6
9	6	1	6
10	36	1	7
11	7	1	8
12	37	1	6
13	8	1	8
14	38	1	7
15	9	1	7
16	39	1	6
17	10	1	7
18	40	1	6
19	11	1	7
20	41	1	6
21	12	1	8
22	42	1	6
23	13	1	8
24	43	1	6
25	14	1	8
26	44	1	6
27	15	1	6
28	45	1	6
29	16	1	6
30	46	1	7
31	17	1	8
32	47	1	6
33	18	1	8
34	48	1	7
35	19	1	6
36	49	1	6
37	20	1	6
38	50	1	7
39	21	1	9
40	51	1	6
41	22	1	6
42	52	1	9
43	23	1	7

44	53	1	9
45	24	1	9
46	54	1	9
47	25	1	6
48	55	1	7
49	26	1	7
50	56	1	7
51	27	1	6
52	57	1	7
53	28	1	7
54	58	1	6
55	29	1	6
56	59	1	9
57	30	1	6
58	60	1	6
59	31	1	6

Figura 16: Consulta de carga total

B. Consulta de análisis multidimensional (Validación del Modelo Estrella)

Para comprobar que las dimensiones están correctamente relacionadas, se ejecutó una consulta que une la tabla de hechos con las tablas de ciudades y tiempo. Esta consulta permite ver los datos de forma legible para un usuario final, sustituyendo los IDs técnicos por nombres de ciudades y fechas reales.

COMANDO:

```
SELECT
    c.NOMBRE_CIUDAD,
    t.FECHA,
    f.INDICE_UV
FROM METEO_ESTRELLA.FACT_RADIACION f
JOIN METEO_ESTRELLA.DIM_CIUDAD c ON f.ID_CIUDAD = c.ID_CIUDAD
JOIN METEO_ESTRELLA.DIM_TIEMPO t ON f.ID_TIEMPO = t.ID_TIEMPO
ORDER BY f.INDICE_UV DESC;
```

RESULTADO:

Resultado de la Consulta

SQL | Todas las Filas Recuperadas: 59 en 0,018 segundos

	NOMBRE_CIUDAD	FECHA	INDICE_UV
1	Palmas de Gran Canaria, Las	16/04/26	9
2	Santa Cruz de la Palma	16/04/26	9
3	San Sebastián de la Gomera	16/04/26	9
4	Puerto del Rosario	16/04/26	9
5	Arrecife	16/04/26	9
6	Valverde	16/04/26	9
7	Santa Cruz de Tenerife	16/04/26	9
8	Ceuta	16/04/26	8
9	Cádiz	16/04/26	8
10	Almería	16/04/26	8
11	Melilla	16/04/26	8
12	Málaga	16/04/26	8
13	Jaén	16/04/26	8
14	Huelva	16/04/26	8
15	Granada	16/04/26	8
16	Alacant/Alicante	16/04/26	7
17	Segovia	16/04/26	7
18	Soria	16/04/26	7
19	Teruel	16/04/26	7
20	Ávila	16/04/26	7
21	Palma	16/04/26	7
22	Murcia	16/04/26	7
23	Madrid	16/04/26	7
24	Ciudad Real	16/04/26	7
25	Cáceres	16/04/26	7
26	Badajoz	16/04/26	7
27	Albacete	16/04/26	7
28	Toledo	16/04/26	7
29	Sevilla	16/04/26	7
30	Córdoba	16/04/26	7
31	Salamanca	16/04/26	7
32	Cuenca	16/04/26	7
33	Eivissa	16/04/26	7
34	Bilbao	16/04/26	6
35	Valencia	16/04/26	6
36	Castellón de la Plana/Castelló de la Plana	16/04/26	6
37	Barcelona	16/04/26	6
38	Coruña, A	16/04/26	6
39	Donostia-San Sebastián	16/04/26	6
40	Girona	16/04/26	6
41	Guadalajara	16/04/26	6
42	Lugo	16/04/26	6
43	Burgos	16/04/26	6

44	Oviedo	16/04/26	6
45	Zaragoza	16/04/26	6
46	Vitoria-Gasteiz	16/04/26	6
47	Valladolid	16/04/26	6
48	Zamora	16/04/26	6
49	Tarragona	16/04/26	6
50	Maó	16/04/26	6
51	Santander	16/04/26	6
52	Lleida	16/04/26	6
53	Logroño	16/04/26	6
54	Pontevedra	16/04/26	6
55	León	16/04/26	6
56	Palencia	16/04/26	6
57	Ourense	16/04/26	6
58	Huesca	16/04/26	6
59	Pamplona/Iruña	16/04/26	6

Figura 17: Consulta de análisis multidimensional

7. Conclusiones

El desarrollo de este proyecto ha permitido consolidar los conocimientos teóricos sobre Business Intelligence mediante una implementación práctica y real. A lo largo del proceso, se ha logrado transformar datos brutos procedentes de la AEMET en un repositorio estructurado bajo un Modelo en Estrella, garantizando la integridad de la información y la eficiencia en las consultas.

Desde un punto de vista técnico, la superación de retos como la configuración del SID en Oracle 21c (ORA-12505) y la gestión de claves subrogadas mediante IDENTITY ha sido fundamental para entender la importancia de la robustez en la capa de datos.

Respecto a las herramientas utilizadas, trabajar con Pentaho Data Integration (Spoon) ha resultado ser una experiencia sumamente entretenida y didáctica. Su interfaz visual basada en flujos de trabajo facilita enormemente la comprensión del ciclo de vida del dato, permitiendo una visión clara de cómo cada transformación impacta en el resultado final. La capacidad de automatizar procesos que manualmente serían tediosos (como el tratamiento de nulos o el formateo de fechas) demuestra el valor de las herramientas ETL en el entorno empresarial actual.

8. Uso de IA

Declaración: Para el desarrollo de este proyecto se ha utilizado la inteligencia artificial generativa Gemini (Google) como asistente técnico y editorial.

Alcance: La IA ha sido empleada en las siguientes tareas:

1. **Depuración de errores:** Resolución del conflicto de conexión ORA-12505 y ajuste de tipos de datos en SQL.
2. **Arquitectura de Datos:** Apoyo en la redacción teórica de la comparativa entre el Modelo en Estrella y el Copo de Nieve.
3. **Desarrollo Editorial:** Ampliación de los apartados de salud pública y redacción de la memoria para asegurar un tono académico y profesional.

Ejemplos de Prompts:

- *"Ayúdame a solucionar el error ORA-12505 en Oracle XE al conectar desde Pentaho."*
- *"Justifica por qué es mejor un Modelo en Estrella que uno en Copo de Nieve para un proyecto de radiación UV."*
- *"Redacta una introducción sobre la AEMET y la importancia de la radiación UV según el Ministerio de Sanidad."*

9. Bibliografía

- **Agencia Estatal de Meteorología (AEMET).** (s.f.). *Quiénes somos: Objetivos y funciones*. Recuperado de: https://www.aemet.es/es/conocenos/quienes_somos
- **Agencia Estatal de Meteorología (AEMET).** (2024). *Valores de radiación solar ultravioleta (UVI): Datos observados y predicción*. [Origen de datos CSV]. Recuperado de: https://www.aemet.es/es/eltiempo/prediccion/radiacionuv?w=0&datos=det
- **Hitachi Vantara.** (s.f.). *Pentaho Data Integration (Spoon) Documentation and User Guide*. Recuperado de: https://help.pentaho.com/
- **Ministerio de Sanidad.** (2023). *Plan Nacional de actuaciones preventivas de los efectos del exceso de temperaturas y radiación sobre la salud*. Madrid: Gobierno de España. Recuperado de: https://www.sanidad.gob.es/areas/sanidadAmbiental/riesgosAmbientales/ultravioleta/home.htm
- **Organización Mundial de la Salud (OMS).** (2022). *Radiación ultravioleta e Índice UV solar mundial*. Ginebra: Ediciones de la OMS.
- **Oracle.** (2021). *Oracle Database Express Edition (XE) Documentation, Release 21c*. Recuperado de: https://docs.oracle.com/en/database/oracle/oracle-database/21/index.html